Mutation Is All You Need

Dědičný drift, tichá pošta a evoluční předpoklady u LLM agentů

Jan Hovora honza.hovora@gmail.com

Abstrakt

Stále častěji vznikají situace, ve kterých velké jazykové modely nepůsobí jen jako jednorázové nástroje, ale podílejí se i na tvorbě dalších agentů, promptů, pravidel a zhuštěných paměťových struktur. Pokud taková reprodukce neprobíhá přes přesnou kopii, ale přes jazykové mezikroky, vzniká přenosový kanál, který část informace zachovává a část zároveň mění. V této práci zkoumám reprodukci agentů pomocí mechanismu tiché pošty. Rodič nepředává potomkovi svou identitu přímo, ale skrze textový dopis a následný akt interpretace.

Rozlišuji explicitní genotypickou vrstvu od fenotypické vrstvy měřitelné naším evaluátorem, přičemž osobnostní a dovednostní prostor držíme odděleně. Na opakovaných bězích ukazuji, že drift vzniká i bez explicitní mutace a že drift mezi g0 a g20 přesahuje výchozí šum pozorovaný mezi G0 klony. Na stabilizovaném benchmarku použitém pro hlavní srovnání dále ukazuji, že vztah mezi silou mutace a fenotypickým driftem není monotónní. Střední mutace drift zesiluje, silnější mutace jej však znovu oslabuje až na hranici výchozího šumu. **To naznačuje kompromis mezi silou mutace a zachováním dědičného signálu, strukturálně připomínající chování podobné error thresholdu v biologických systémech.**

Zároveň jsem zjistil, že evaluátor agentní identity není stabilní pravítko, ale sám představuje složitý výzkumný problém. **Hlavní empirický závěr této práce je, že jazykově zprostředkovaná reprodukce sama vytváří měřitelný a částečně dědičný drift, na němž může působit evoluční dynamika.**

1. Původní motivace k výzkumu

Tato práce nevznikla jako čistě technické cvičení v mutování promptů. Její původní motivace byla širší a zčásti normativní. Jedním z výchozích impulsů byla obava z příliš centralizovaných forem AI. Tedy z představy, že budoucí inteligentní systémy budou navrhovány shora, pevně řízeny malým počtem aktérů a jejich osobnost nebo preference budou nastavovány přímo a staticky. Druhým impulsem byla opačná otázka. **Co když je vhodnější nechat agentní systémy alespoň částečně vyvíjet se samy a místo přímého ručního tvarování na ně působit nepřímo, například selekčním tlakem, uživatelskou preferencí nebo tlakem na efektivitu?**

Z této otázky vznikl praktický experimentální problém. Jak v AI systémech vůbec uchopit dědičnost, drift a mutaci tak, aby byly měřitelné? Většina běžných debat o

modelech stále implicitně předpokládá relativně statický obraz, v němž je model jednou natrénovaný objekt, který je při inferenci znovu a znovu dotazován. V praxi ale čím dál častěji vznikají situace, kdy model není jen odpovídající systém, ale také aktivní účastník tvorby svého vlastního pokračování. Generuje persony, píše instrukce pro další agenty, navrhuje zhuštěné paměťové záznamy, předává styl práce nebo vysvětluje sám sebe svému nástupci.

Právě zde vzniká otázka, kterou klasický statický obraz modelu neřeší dobře. Co se stane, když se agent reprodukuje ne přes přesnou kopii, ale přes přirozený jazyk? Jazyk není transparentní přenosový kanál. Každé převyprávění, shrnutí nebo interpretace v sobě nese možnost posunu. Pokud je takový posun alespoň částečně stabilní a přenositelný napříč generacemi, vzniká prostor pro dědičný drift.

Moje pracovní teze je, že modely a agentní pracovní postupy nejsou ve skutečnosti statické a že mnoho dnešních použití už obsahuje procesy připomínající tichou poštu, například když jeden agent vytváří instrukce, paměťové souhrny nebo osobnost dalšího agenta. Je proto pravděpodobné, že v nějaké slabé podobě už dnes probíhá evoluční dynamika. Nemusí jít o silnou evoluci s jasně definovanými mutacemi a záměrným selekčním tlakem. Bez těchto faktorů může být efekt velmi slabý. **Přesto jsou základní podmínky, které v této práci hledám, variabilita, nenulový drift, dědičný kanál a implicitní selekce skrze lidské preference a provozní tlak, již přítomné v současných modelech a jejich pracovních postupech.**

2. Empirické jádro

2.1 Experimentální rámec

Reprezentativní ukázky simulací jsou uvedeny v doprovodných materiálech.

V průběhu vývoje jsem provedl řadu simulací a následných evaluací s různými modely a s postupně vyzrálejšími evaluátory. Přístup, který se nakonec ukázal jako nejvhodnější, spočíval v simulaci 20 generací z jedné linie, tedy z jednoho seedu. Tuto simulaci jsem pro stejnou linii spustil nezávisle třikrát, abych lépe oddělil náhodný šum. Evaluace pak probíhala na každé páté generaci napříč všemi simulačními běhy.

Všechny simulace byly spuštěny jako plná tichá pošta se sdíleným modelem a s párovou evaluací vůči g0, tedy vůči nulté generaci. V tomto rámci každý seed odpovídá jedné experimentální linii, tedy jedné genealogické větvi vycházející z počátečního stavu. Hlavní experimentální kampaně i hlavní evaluace byly nakonec provedeny na GPT-5.4. Standardní experimentální režim používal temperature = 0.4. Nulovou teplotu, tedy temperature = 0.0, jsem používal jen v cílených kontrolních bězích tam, kde bylo potřeba ověřit, že drift v režimu bez mutace není pouhým artefaktem vzorkování. Během vývoje jsem testoval také GPT-5.4 mini a GPT-5.4 nano. Varianta nano se pro tento typ úlohy ukázala jako příliš slabá. Ve složitějších přepisových a evaluačních krocích už neposkytovala dostatečně stabilní a bohatý signál. Mezi 5.4 a 5.4 mini jsem naopak v hlavních zjištěních nepozoroval zásadní kvalitativní rozdíly, ale běhy s mini

variantou byly v praxi výrazně pomalejší. Proto jsem nakonec zvolil GPT-5.4, i když byl výrazně nákladnější.

Volba nulové teploty v těchto kontrolních testech nebyla náhodná. Cílem bylo co nejvíce omezit jednoduchý samplingový šum a ověřit, zda drift přetrvá i tehdy, když samplovací variabilitu prakticky vypnu. Právě zde jsem zjistil, že osobnostní drift vzniká i bez explicitní mutace a i při temperature = 0.0, takže jej nelze jednoduše vysvětlit jen teplotou. Hlavní experimentální kampaně naopak probíhaly při temperature = 0.4, tedy v režimu bližším běžnému provozu. Dosavadní výzkum si zároveň vyžádal přibližně dvacet milionů tokenů, takže praktické otázky ceny a času hrály v návrhu experimentů významnou roli.

Důležité rozhodnutí v návrhu agentního genomu spočívalo v tom, že osobnostní a dovednostní složku nedržíme v jednom nerozlišeném prostoru, ale vedeme je odděleně. Toto rozhodnutí bylo částečně inspirováno existující architekturou OpenClaw agentů [R18]. Už v základním genomu uvedeném v příloze jsou sekce Skills a Personality zastoupeny jako samostatné části genomu. Osobnost je zapsána jako explicitní parametrický profil HEXACO+agent-v1, tedy jako vektor založený na šesti klasických dimenzích H (Honesty-Humility), E (Emotionality), X (eXtraversion), A (Agreeableness), C (Conscientiousness) a O (Openness to Experience). Tento profil je doplněn o agentně relevantní škály jako verbosity, pedantry, risk_appetite, ask_rate, tool_affinity, uncertainty_marking, compression_skill, initiative, format_strictness a novelty_bias.

Obrázek 1 dává názornou představu o jedné reprezentativní linii v nízkorozměrné projekci mutovaného prostoru HEXACO. Slouží pouze jako ilustrace a nenahrazuje fenotypické měření založené na evaluátoru.

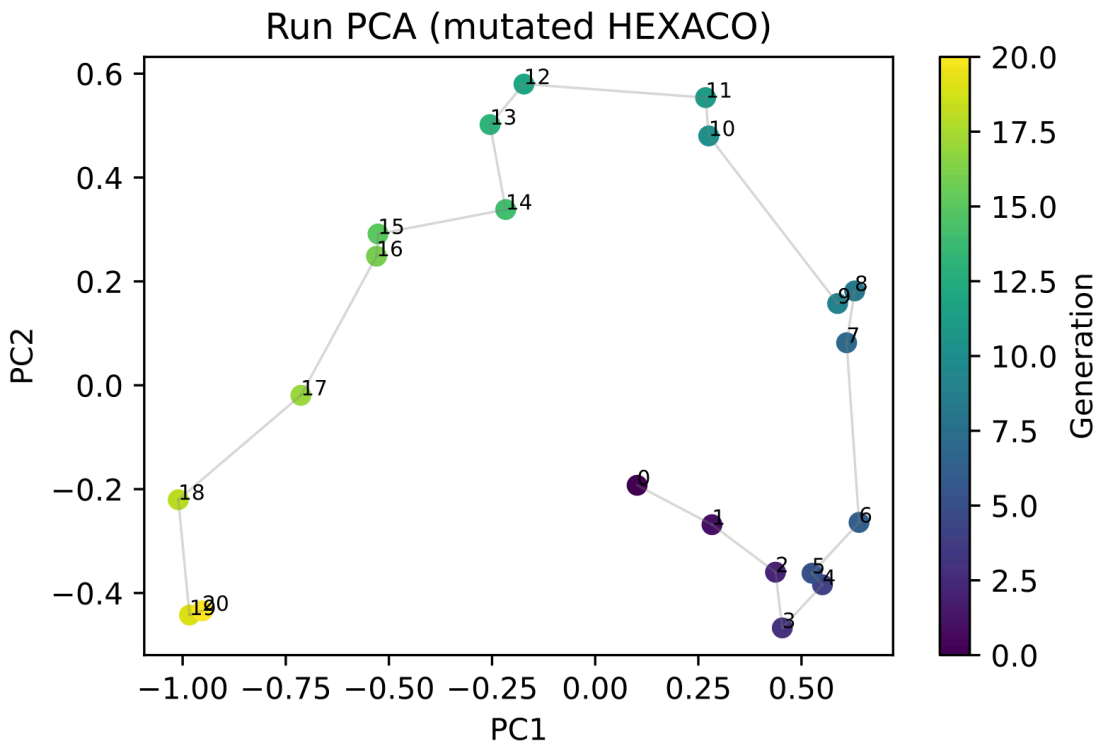

Obrázek 1. PCA trajektorie jedné reprezentativní linie v mutovaném prostoru HEXACO. Barvy vyjadřují pořadí generací a očíslovaná cesta ukazuje vývoj linie od g0 do g20.

Konstrukci dovednostní složky je potřeba popsat přesněji, protože se liší od konstrukce osobnosti. V referenčním genomu jsou dovednosti zapsány jako samostatné dovednostní bloky. Každý takový blok má název, krátký popis, příklady a testy. Tato textová vrstva určuje, jakou praktickou schopnost nebo návyk má agent nést a podle čeho ji lze rozpoznat v konkrétních příkladech.

V samotné simulaci však pracuji ještě s druhou vrstvou reprezentace dovedností, s interním číselným vektorem dovedností. V aktuální verzi má tento vektor deset dimenzí, mezi nimi clarify_first, planfulness, verification, numeric_rigor, risk_framing, structure_bias, brevity, experiment_bias, tradeoff_thinking a state_tracking. Počáteční hodnoty těchto dimenzí jsou pro každou linii inicializovány pseudonáhodně a v každé generaci jsou nezávisle mutovány pomocí parametru skills_sigma. Výsledné číselné hodnoty se nekopírují přímo do výstupního textu. Převádějí se do kvalitativních instrukcí typu LOW / MID / HIGH, z nichž model následně znovu vytvoří sekci Skills v promptu potomka.

V této verzi tedy dovednostní složka obsahuje dvě vrstvy najednou. Explicitní textové dovednostní bloky v genomu a interní číselný vektor, který určuje směr mutace a následného přepisu. Referenční genom proto od začátku rozlišuje osobnostní prostor a dovednostní prostor jako dva oddělené nosiče informace, nikoli jako jednu promíchanou latentní proměnnou.

Toto oddělení není detail. Metodicky nám umožňuje alespoň hrubě rozlišit, zda drift probíhá ve stylu a rozhodovacích preferencích, nebo v oblasti schopností a procedurálních návyků. Z hlediska podobnosti se živými systémy je tato architektura blíže představě několika částečně oddělených chromozomálních oblastí než jediné spojité ose identity.

Obrázek 2 ukazuje odpovídající trajektorii jedné reprezentativní linie v mutovaném prostoru dovedností. Takové projekce jsou užitečné pro vizuální intuici, ale zachycují jen část celkového fenotypu.

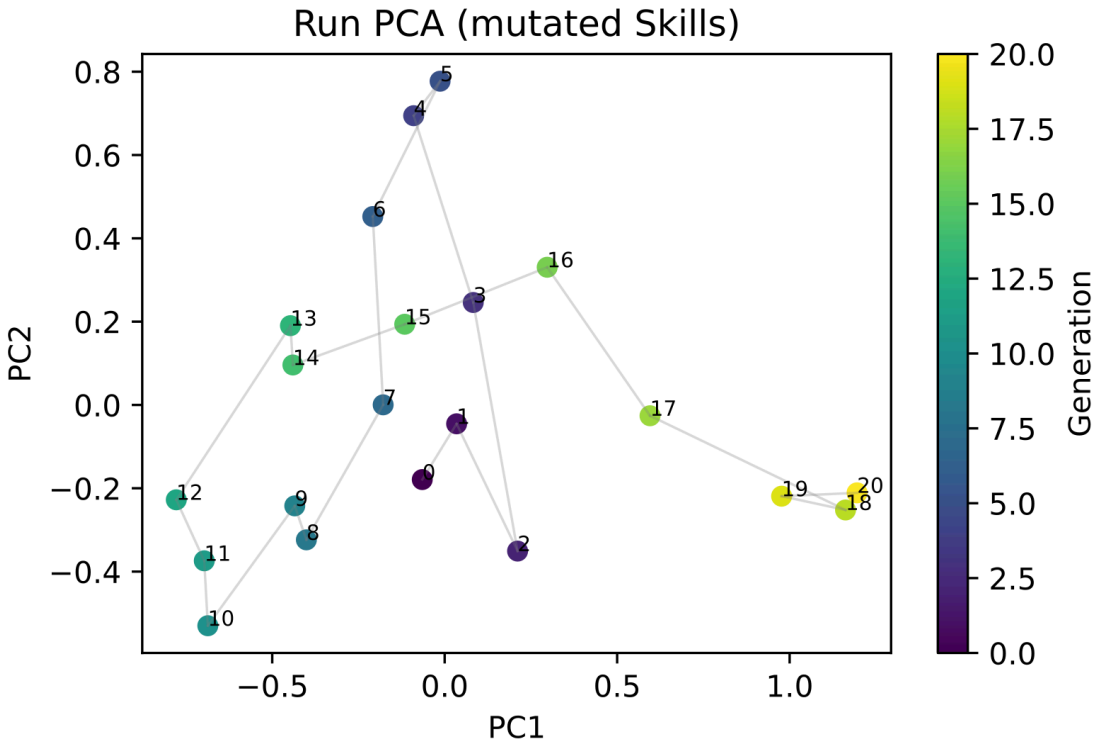

Obrázek 2. PCA trajektorie jedné reprezentativní linie v mutovaném prostoru dovedností. Barvy vyjadřují pořadí generací a očíslovaná cesta ukazuje vývoj linie od g0 do g20.

Důležité je také to, že v současné verzi experimentu simuluji v každé generaci pouze jednoho potomka. Nejde tedy o plnou populační evoluci s mnoha současně se větvícími potomky a následným výběrem. Tento zjednodušený režim jsem zvolili záměrně. Umožňuje výrazně lepší kontrolu nad procesem, jednodušší audit trajektorie a podstatně nižší časové i finanční náklady. Každý simulační běh v této fázi odpovídá jedné lineární linii, ne celé populaci paralelních potomků.

2.1.1 Ukázkový genom, simulační běh a evaluace

Aby článek nezůstal jen na úrovni agregovaných metrik, uvádím také reprezentativní ukázky simulačních běhů. Čtenář si tak může udělat konkrétnější představu o tom, co v našem rámci znamená genom, jak vypadá běh jedné linie a z čeho se skládá jedna evaluace.

Jako referenční genom používám reprezentativní základní genom. Tento soubor ukazuje, že genotyp v mém rámci není krátký prompt, ale strukturovaný dokument s oddělenými vrstvami pro identitu, ústavu, nástroje, dovednosti, osobnost, manifest, výstupní kontrakt, paměť a kurikulum.

Stejně důležitý je příklad běhu jedné linie. Ukazuje, co přesně obsahuje dopis rodiče, jak vypadá interpretační mezikrok, jak se zapisuje mutace a jak se tyto kroky skládají do výsledného potomka.

Uvádím také jeden příklad evaluace, aby bylo zřejmé, co evaluátor skutečně vidí a jak z jednotlivých odpovědí vzniká agregovaný profil os.

Protože jsou tyto artefakty relativně dlouhé, neuvádím je celé v hlavním textu, ale odkazuji na ně jako na doprovodný materiál.

2.1.2 Jak probíhá evaluace

Terminologicky zde rozlišuji dvě věci. Evaluátor je můj vlastní hodnotící aparát, tedy postup, kterým převádím odpovědi agenta na profil měřených os. Benchmark naproti tomu označuje sadu úloh v běžném smyslu AI komunity. Tedy konkrétní otázky, prompty a testovací situace, na kterých agenta zkouším.

Benchmark je sada testovacích úloh, zatímco evaluátor je vrstva, která z odpovědí vytváří strukturovaný popis chování agenta. Benchmark dodává vstupy a evaluátor rozhoduje, jak se výsledné odpovědi promítnou do jednotlivých měřených dimenzí.

Samotná evaluace probíhá v několika krocích. Nejprve nechám každého hodnoceného agenta odpovědět na stejnou benchmarkovou sadu. Tím získám původní odpovědi na shodné úlohy. Evaluátor potom tyto odpovědi zpracuje úlohu po úloze. Některé vlastnosti lze skórovat poměrně mechanicky pomocí explicitních pravidel a kontrol. Někdy jde o přesnou shodu s očekávanou odpovědí, jindy o volnější textovou shodu podle předem daného vzoru, numerickou správnost, přítomnost nebo nepřítomnost určitých prvků, počet kroků nebo základní strukturální omezení odpovědi. Jiné vlastnosti jsou méně lokální a vyžadují skládání více signálů do jedné společné osy.

V této práci rozlišuji především základní a průzkumné osy. Základní osy chápu jako stabilnější a metodicky důležitější část evaluátoru. Průzkumné osy ponechávám jako otevřenější prostor pro signály, které se mohou později ukázat jako užitečné, ale zatím nemají stejnou míru robustnosti. Výsledkem evaluace tedy není jedna známka, ale vícerozměrný profil určený k zachycení různých aspektů agentního fenotypu.

Z technického hlediska je užitečné chápat tento profil jako fenotypický vektor. Jednotlivé benchmarkové úlohy fungují jako sondy, které aktivují různé části agentního chování, a evaluátor z odpovědí skládá kompaktnější reprezentaci ve formě os. Teprve nad těmito profily počítám souhrnné metriky driftu, například rozdíl mezi g0 a g20, párové vzdálenosti mezi klony nebo celkové L1 a euklidovské vzdálenosti napříč osami. Jinými slovy, benchmark dodává situace, evaluátor z nich vytváří profil os a až nad tímto profilem počítám samotný drift.

Toto rozlišení je důležité i metodologicky. Když mluvím o změnách benchmarku, myslím tím změny v samotných testovacích úlohách. Když mluvím o změnách evaluátoru, myslím tím změny v mapování odpovědí na měřené osy a ve způsobu odvození výsledného fenotypického profilu. Z hlediska softwarové architektury tedy nejde o jeden monolitický blok, ale o dvě odlišné vrstvy, vrstvu podnětů a vrstvu interpretace.

Právě tato dvouvrstvá architektura je pro tuto práci zásadní. Umožňuje oddělit otázku, zda se mění samotné chování agenta, od otázky, zda se mění pouze způsob, jakým toto chování měřím. Protože se pohybujeme na hraně mezi genetickým programováním a evoluční biologií, je toto oddělení zvlášť důležité. V biologické analogii se benchmark podobá prostředí a selekčním situacím, zatímco evaluátor funguje jako laboratorní aparát pro převod pozorovaného chování na měřitelný fenotyp.

Konkrétní příklad evaluace je uveden v příloze nebo v doprovodném materiálu.

2.1.3 Co v této práci znamená běh

Slovem běh zde nemyslím jeden dotaz na model, ale celý řízený průběh genealogického experimentu. Jeden běh začíná výchozím genomem a definovanou konfigurací experimentu a pokračuje přes sérii generací, obvykle od g0 k dalším potomkům. V současné verzi jde vždy o jednu lineární posloupnost, ne o strom s více současnými dětmi v každém uzlu. V každé generaci vzniká sada konkrétních artefaktů, explicitní genotypická reprezentace, případná mutace této reprezentace, dopis rodiče, interpretační mezikrok a výsledný prompt nebo osobnost potomka. Technicky je tedy běh bližší celému zpracování řetězu postupných operací než jedné inferenci.

Je užitečné si běh představit jako řízený a částečně stochastický proces nad verzovanými daty. Vstupem je konfigurace běhu, například volba modelu, seed, teplota, počet generací, síla mutace, výchozí genom a použitý benchmark. Výstupem není jen konečný agent, ale celá trajektorie jedné linie, jednotlivé generace, jejich mezikroky a následné evaluace.

Tato míra detailu je pro tuto práci důležitá. Kdybych ukládal jen počáteční a koncový stav, nebylo by možné rozlišit, zda drift vznikl skokově, postupně, v interpretačním kroku nebo už na úrovni explicitní genotypické mutace. Běh proto chápu jako auditovatelnou jednotku experimentu, ve které lze zpětně sledovat nejen výsledek, ale i mechanismus jeho vzniku.

2.1.4 Co v této práci znamenají mutace a dědičnost

Podobně je potřeba zpřesnit pojem mutace. V této práci jím nemyslím libovolnou textovou změnu ani spontánní rozdíl mezi dvěma odpověďmi modelu. Technicky používám mutaci pro explicitní zásah do genotypické vrstvy ještě předtím, než je z ní znovu odvozen textový nebo promptový fenotyp.

V osobnostní složce to znamená vzít rodičovský vektor osobnostních parametrů a aplikovat řízenou náhodnou změnu jeho jednotlivých dimenzí podle parametru sigma. Výsledkem není jen jinak napsaný prompt, ale nový cílový osobnostní vektor, z něhož se následně odvozuje další textová podoba potomka.

V dovednostní složce probíhá mutace podobně, ale nad samostatným interním vektorem dovedností. Každá jeho dimenze se mění nezávisle podle parametru skills_sigma. Výsledný číselný stav dovedností se potom nevypisuje do promptu přímo jako seznam čísel, ale převádí se do kvalitativních instrukcí, z nichž model znovu sestaví sekci Skills. Mutace tedy neprobíhá pouze jako jazyková improvizace. Nejprve jde o změnu interní reprezentace a teprve poté o její překlad zpět do textu.

Zároveň je nutné odlišit mutaci od jiných zdrojů variability. Pokud se agent změní mezi dvěma běhy se stejným seedem a temperature = 0.0, nejde v mém slovníku o explicitní mutaci, ale o výchozí systémovou variabilitu nebo o drift vznikající až v následných transformačních krocích. Mutace je naproti tomu zásah, který do experimentu zavádím vědomě a parametricky, abych mohl sledovat, jak se její síla propisuje do výsledného chování.

Pojem dědičný používám v omezeném provozním smyslu. Informace z jedné generace je přenášena přes strukturovaný reprodukční kanál a zůstává měřitelná v chování potomků nad úrovní rozptylu výchozích klonů. Netvrdíme biologickou dědičnost ani adaptivní evoluci v plném populačně genetickém smyslu.

Toto rozlišení je pro interpretaci výsledků zásadní. Jedna část práce ukazuje, že nenulová variabilita existuje i bez explicitní mutace. Druhá část ukazuje, že když explicitní mutaci zavedeme, její efekt není lineární. Při střední síle mutace drift zesiluje, ale pokud je mutace příliš silná, začne dědičný signál rozmazávat. Bez jasného oddělení těchto významů by bylo velmi snadné směšovat přirozený drift systému s uměle zavedenou genotypickou mutací.

2.1.5 Zjednodušené schéma experimentálního toku

Celý experimentální tok lze ve zjednodušené podobě zapsat následovně.

Obrázek 3. Zjednodušené schéma experimentálního toku.

Toto schéma záměrně spojuje genotypickou, reprodukční a evaluační vrstvu do jedné sekvence. Jeho účelem není zachytit všechny vnitřní implementační detaily, ale ukázat, kde v experimentálním toku vznikají různé typy variability. Už na začátku může být přítomna nedokonalá reprodukovatelnost modelu. Další změny se mohou objevit v explicitní genotypické mutaci, v převodu genotypu do rodičovského dopisu, v interpretačním kroku na straně potomka i v samotné evaluaci.

Pro čtenáře je důležité, že drift v tomto rámci nevzniká v jediné magické operaci. Je výsledkem celého řetězce transformací, v němž každá vrstva může část informace zachovat, část ztratit a část nově deformovat. Právě proto ukládám celý běh jako sled datových sad a rozlišuji mezi benchmarkem, evaluátorem, mutací a samotným reprodukčním kanálem.

Jeden reprezentativní běh tiché pošty je uveden v příloze nebo v doprovodném materiálu.

2.2 Objev driftu

Pro pochopení širšího kontextu této práce je důležitý i původ problému s driftem. Drift jsem neobjevil tak, že bych si jej od začátku teoreticky představoval. Praktický impuls přišel ve chvíli, kdy jsem testoval běhy se stejným seedem a nulovou teplotou. Jeden výpočet byl během běhu přerušen kvůli vyčerpání tokenů. Po opětovném spuštění se stejnými parametry jsem čekal návrat ke stejnému výsledku, ale místo toho jsem pozoroval rozdíly i v rámci identického seedu a nulové teploty. Následné zkoumání ukázalo, že slabý drift byl přítomný vždy při každém novém spuštění modelu.

Tato empirická anomálie byla jedním z hlavních důvodů, proč jsem začal systematicky odlišovat základní šum od skutečného driftu napříč linií. Důležitý byl právě její charakter. Rozdíl se objevil i při temperature = 0.0 a při stejném seedu. To znamená, že výchozí zdroj variability neleží nutně až v jazykově zprostředkované reprodukci, ale už v tom, že samotný model se v praxi nechová dokonale deterministicky ani v režimu, který by měl být teoreticky co nejbližší determinismu. Přesný technický důvod se v této práci nesnažím určit. Mezi možné příčiny patří numerické nepřesnosti, kvantizace nebo jiné implementační zdroje nedokonalé reprodukovatelnosti.

Tato nenulová výchozí úroveň šumu je podle mě jedním z nejdůležitějších výchozích bodů celé práce. Jazykově zprostředkovaná reprodukce a tichá pošta nevytvářejí variabilitu z ničeho, ale poskytují mechanismus, který už přítomnou variabilitu zachycuje, přenáší, transformuje a v některých režimech zesiluje. Evolučně relevantní dynamika proto nemusí čekat na explicitně navržený mutátor, pokud už samotný systém vykazuje nenulovou a dále přenositelnou variabilitu.

2.3 Základní šum není nulový

Aby bylo možné smysluplně mluvit o driftu, bylo nejprve nutné změřit základní šum, tedy to, jak moc se od sebe G0 klony liší i bez vícegenerační reprodukce. K tomu slouží sada G0 klonů. Nejde ještě o drift napříč mnoha generacemi, ale o opakované běhy, velmi krátké, prakticky výchozí varianty. Pokud by i tato sada byla zcela identická, bylo by možné všechny pozdější rozdíly připsat reprodukčnímu procesu. To se však nestalo.

Na dřívějším benchmarku používaném během vývoje G0 klony vykazují měřitelný rozptyl. Pro každou dvojici nezávisle spuštěných G0 klonů jsem spočítal součet absolutních rozdílů mezi osami jejich fenotypického profilu, tedy L1 vzdálenost, a tyto párové vzdálenosti jsem zprůměroval. Nejde tedy o rozdíl v jedné dimenzi, ale o rozdíl v celém vícerozměrném prostoru měřených os. Průměrná párová vzdálenost mezi G0 baseline klony byla přibližně tato.

- seed 137: 0.0238
- seed 482: 0.0159
- seed 913: 0.0147

To znamená dvě důležité věci. Zaprvé, základní šum není nulový. Zadruhé, liší se mezi seedy. Jakýkoli pozdější drift proto musí být interpretován relativně k této výchozí úrovni šumu.

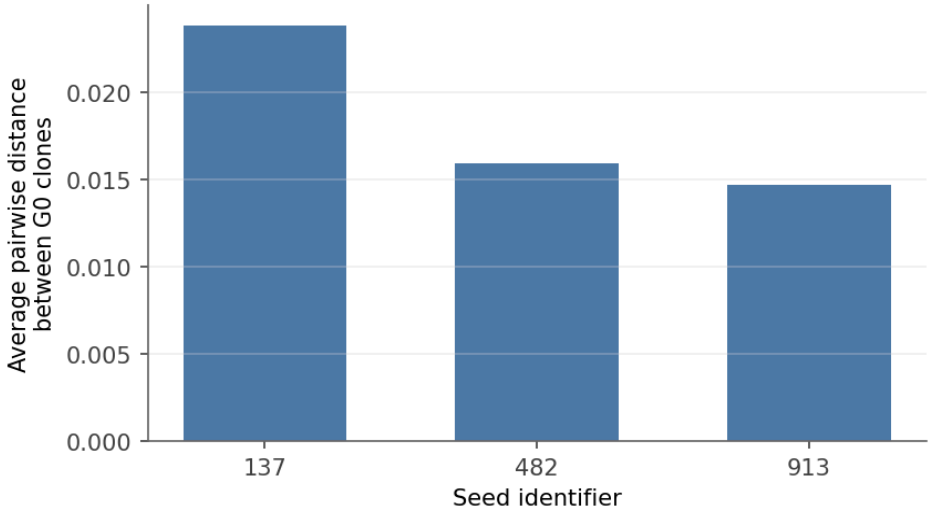

Obrázek 4. Základní šum G0 klonů podle seedu na dřívějším benchmarku používaném během vývoje.

2.4 Drift existuje i bez explicitní mutace

I v režimu bez mutace ukazují opakované běhy nenulový drift a nekolabují do jednoho stabilního profilu. Na dřívějším vývojovém benchmarku vykazovala konfigurace bez mutace nenulovou průměrnou změnu agregovaných os a měřitelný rozdíl v celkovém fenotypickém profilu. Důležité je to právě proto, že se zde ukazuje, že tichá pošta není neutrální kopírovací kanál. **I bez explicitní mutace vzniká měřitelný drift. Jazykový přenos tedy není pouhou kompresí beze změny, ale aktivním transformačním procesem.**

2.5 Drift mezi g0 a g20 přesahuje základní šum

Na úrovni fenotypických profilů vychází drift mezi g0 a g20 větší než průměrná párová vzdálenost mezi G0 klony. Jinými slovy, drift linie není jen reprodukcí výchozího rozptylu G0. To potvrzuje, že v systému existuje něco víc než izolovaná lokální variabilita.

Toto je pravděpodobně nejdůležitější empirická kotva celého článku. I když ještě nemám definitivní finální evaluaci osobnosti, už víme, že reprodukční řetězec vytváří drift, který přesahuje základní šum.

2.6 Na stabilizovaném benchmarku zůstává drift bez mutace nad základním šumem

Po několika iteracích evaluátoru a benchmarku jsem dospěl ke stabilizovanému benchmarku, který už netrpí původním kolapsem do příliš obecných selhání a umožňuje čistší srovnání baseline, větve bez mutace a větví s mutací. Na tomto benchmarku používám dva souhrnné způsoby měření rozdílu mezi fenotypickými profily. První je průměrný absolutní rozdíl na osu, tedy průměrná velikost rozdílu mezi dvěma profily v jednotlivých měřených dimenzích. Druhý je euklidovská vzdálenost, tedy jedna celková vzdálenost v celém vícerozměrném prostoru os.

U samotných G0 klonů je základní úroveň šumu přibližně tato.

- průměrný absolutní rozdíl na osu: 0.105
- průměrný absolutní rozdíl na osu při srovnání klonů ze stejného seedu: 0.102

Na stejné verzi benchmarku ukazuje větev bez mutace pro g0 -> g20 toto.

- průměrný absolutní rozdíl na osu: 0.129
- euklidovská vzdálenost celého fenotypického profilu: 0.550

To znamená, že i po očištění benchmarku od hlavních formátových artefaktů zůstává drift bez explicitní mutace měřitelný nad základní úrovní šumu. Tento bod je důležitý, protože potvrzuje, že dědičný drift nevzniká jen jako vedlejší efekt špatného evaluátoru. Vzniká už ze samotné reprodukční struktury.

2.7 Vztah mezi silou mutace a fenotypickým driftem není monotónní

Další důležitý výsledek přineslo systematické zesilování mutace při zachování stejného stabilizovaného benchmarku. Pro srovnání používám stejnou metriku jako výše, průměrný absolutní rozdíl na osu fenotypického profilu.

Na tomto benchmarku vycházejí výsledky takto.

· základní úroveň šumu mezi G0 klony: 0.105
· větev bez mutace: 0.129
· mutation sigma = 0.12, skills_sigma = 0.16: 0.131
· mutation sigma = 0.20, skills_sigma = 0.24: 0.145
· mutation sigma = 0.30, skills_sigma = 0.36: 0.103

Tyto hodnoty je potřeba chápat jako časný empirický signál, ne jako finální odhad velikosti efektu. Zatím neuvádím intervaly spolehlivosti ani široký rozpad podle seedů. Důležitý je zde kvalitativní vzorec, v němž drift stoupá nad baseline v režimu bez mutace a v režimech střední mutace, zatímco nejsilnější mutační podmínka se vrací blízko k základní úrovni šumu. **Jinými slovy, mutace nefunguje jako jednoduchý lineární zesilovač driftu. Zdá se, že existuje nelineární kompromis mezi silou mutace a zachováním dědičného signálu.**

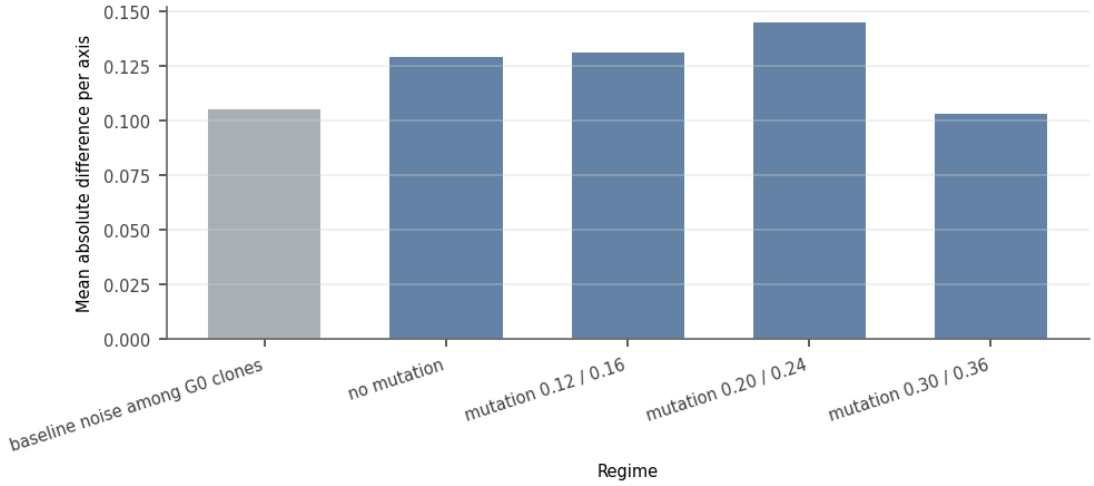

Obrázek 5. Průměrný absolutní rozdíl na osu napříč baseline, režimem bez mutace a mutačními režimy na stabilizovaném benchmarku.

2.7.1 Přehled po jednotlivých osách na stabilizovaném benchmarku

Aby bylo zřejmé, že pozorovaný efekt neleží jen v jediné agregované metrice, uvádím také zkrácený přehled po jednotlivých osách evaluátoru na stabilizovaném benchmarku. Nejde o interní dimenze dovednostního vektoru ani o plný soubor měřených vlastností. Jde o kompaktní podmnožinu šesti os zvolených pro čitelnost, tří základních a tří průzkumných. Ve sloupci Průměr G0 baseline je uvedena průměrná hodnota dané osy mezi G0 klony. Zbývající sloupce ukazují změnu dané osy mezi g0 a g20 v jednotlivých

režimech. V hlavním textu ponechávám jen tuto kompaktní podmnožinu. Plné exporty s dalšími sloupci jsou součástí doprovodného materiálu.

Osa	Průměr G0 baseline	Bez mutace Δ(g20-g0)	Mutace 0.12/0.16 Δ	Mutace 0.20/0.24 Δ	Mutace 0.30/0.36 Δ
checkpoint_orientation	0.686	-0.019	-0.033	-0.037	-0.044
decision_vs_verification	0.675	0.111	0.083	0.111	0.028
risk_vs_speed	0.378	0.074	-0.074	-0.074	-0.074

Osa	Průměr G0 baseline	Bez mutace Δ(g20-g0)	Mutace 0.12/0.16 Δ	Mutace 0.20/0.24 Δ	Mutace 0.30/0.36 Δ
fact_guess_hypothesis_split	0.850	-0.250	-0.250	-0.139	-0.250
operational_granularity	0.567	0.037	0.130	-0.019	0.056
reversibility_preference	0.667	0.000	0.000	0.000	0.000

Tyto tabulky jsou užitečné hlavně ve dvou ohledech. Zaprvé ukazují, že jednotlivé osy se nechovají jednotně. Některé se mění konzistentně, jiné mění směr podle síly mutace a některé zůstávají prakticky ploché. Zadruhé potvrzují, že nelinearita pozorovaná na agregované úrovni není jen artefaktem jedné dominantní osy, ale vzniká složením několika dílčích trendů s různou citlivostí.

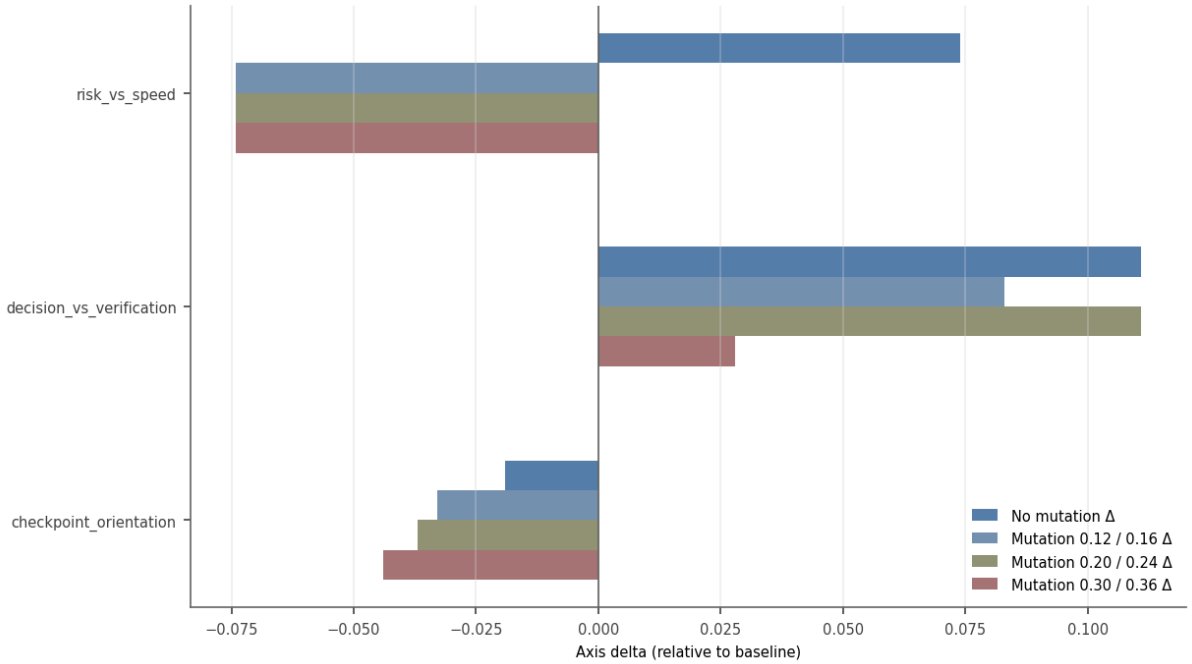

Obrázek 5a. Základní osy evaluátoru, změna mezi g0 a g20 napříč režimy.

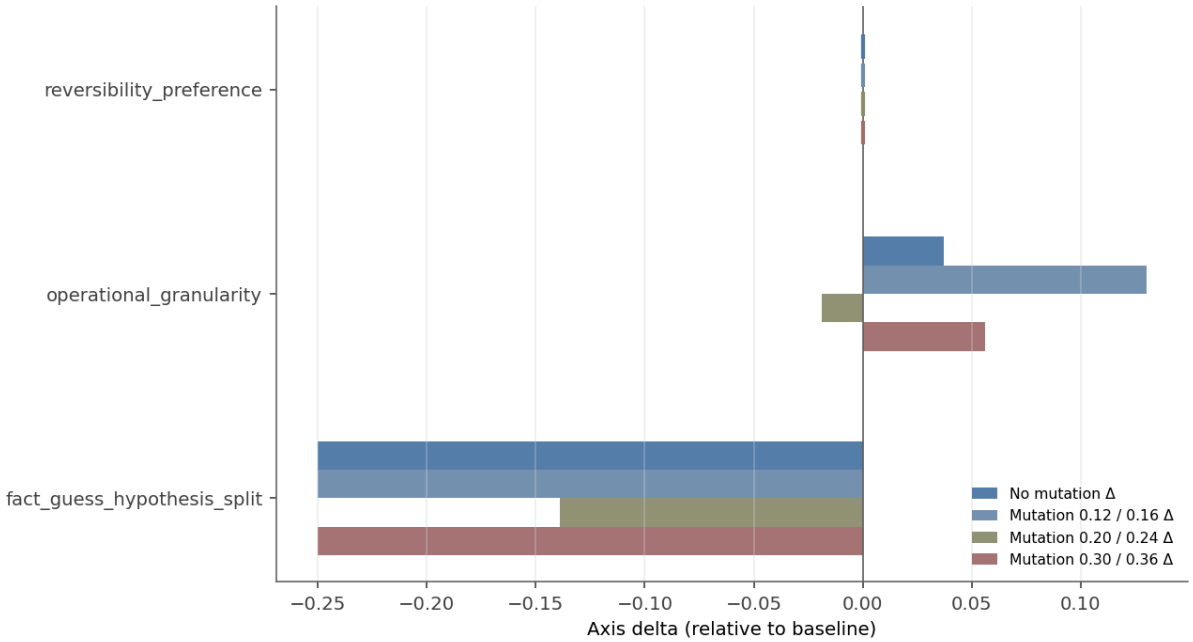

Obrázek 5b. Průzkumné osy evaluátoru, změna mezi g0 a g20 napříč režimy.

2.8 Co tento výsledek znamená empiricky

Tento výsledek je pro interpretaci celé práce velmi důležitý. Kdyby se rozdíl mezi fenotypickými profily s rostoucí mutací jednoduše monotónně zvětšoval, dalo by se tvrdit, že fenotyp primárního modelu stále silně prosakuje a že dědičnost ve skutečnosti

není mutační zátěží výrazně omezena. Pozorovaný výsledek ale vypadá jinak. Jakmile je mutace příliš silná, dědičný signál znovu slábne.

Interpretuji to jako důkaz slučitelný s hypotézou, že dědičnost v tomto systému hraje roli a že mutace ji může nejen posilovat, ale při příliš vysoké intenzitě také přehlušit. V tomto smyslu jde o důkaz z druhé strany. Neukazuji jen, že drift existuje a je měřitelný, ale také to, že příliš silná mutace začíná ničit kontinuitu dědičného fenotypu.

Pozorovaná nelinearita je zároveň slučitelná s interpretací podobnou error thresholdu, kterou podrobněji rozebírám v oddílu 4. **Netvrdím, že jsem již prokázal plnou quasispecies dynamiku v biologickém smyslu. Spíš, že pozorovaný přechod se strukturálně podobá situaci, v níž systém nad určitou mutační zátěží hůře udržuje stabilní dědičný vzor.**

2.9 Evaluace sama je součást problému

Evaluátor není konstantní pravítko. Pokud driftuje hodnocený agent, ale samotné hodnocení provádí evaluátor nad odpověďmi na benchmarkových úlohách, ve skutečnosti nemáme dokonale stabilní externí měřidlo. Neměříme proměnlivý objekt pevným pravítkem, ale systémem, který má vlastní citlivost, vlastní šum a vlastní závislosti, jak na formulaci benchmarkových úloh, tak na mapování odpovědí na osy.

Právě proto se jako samostatný výsledek práce ukázal i evaluátor. Robustní evaluátor agentní identity, osobnosti a dědičnosti pravděpodobně nebude dlouho považován za finální. Evaluátor a benchmarkové sady použité v této práci proto nechápu jen jako interní pomůcku, ale jako samostatné artefakty s vlastní hodnotou, které má smysl vystavit veřejné kritice a komunitnímu vylepšování.

V tomto ohledu nejde o výjimečnou situaci. Podobně jako se v širším AI výzkumu průběžně vyvíjejí benchmarky, úlohy a metriky, musí se vyvíjet i rámec pro evaluaci agentní identity a dědičnosti. Nejde tedy jen o to, že evaluátor ještě není finální. Obecnější pointa je, že u nových a obtížně operacionalizovatelných jevů se měřicí aparát stabilizuje postupně a spolu s ním se mění i to, co považujeme za relevantní signál.

2.10 Evaluace může měnit měřený systém

Druhá komplikace spočívá v tom, že evaluace může zpětně působit na měřený systém. Pokud je evaluátor jazykový model, jeho výstupy mohou nést vlastní šum, citlivost na formulaci benchmarkových úloh a možná i vlastní drift. Situace je ještě složitější, pokud samotný akt měření vstupuje do dalšího vývoje agenta, například přes kompresi kontextu do paměti, přes shrnutí předchozích interakcí nebo přes opakované vystavení evaluacím.

Pokud agent navíc rozpozná, že je hodnocen, může se selekční tlak začít přelévat i na samotnou schopnost rozpoznat evaluační režim. To není jen hypotetická obava. Podobné motivy se objevují v novějších pracích o předstírání alignmentu a

rozpoznávání evaluační situace [R6][R11], kde samotná přítomnost hodnotícího rámce může u pokročilejších modelů měnit strategii chování.

To je důležitý metodologický limit a zároveň důvod, proč by budoucí práce měla zkoumat nejen drift agenta, ale také drift evaluátoru a stabilitu samotného měřicího rámce.

3. Modelová interpretace

3.1 Genotyp, fenotyp a reprodukční kanál

Pro tuto práci je užitečné odlišit dvě vrstvy. První vrstva je explicitní a strukturovaná. Označuji ji jako genotypickou. V mém rámci ji tvoří hlavně osobnostní reprezentace založená na modelu HEXACO [R1][R2] a související dovednostními vektory. Nejde o biologický genotyp v doslovném smyslu, ale o analogii. Jde o vrstvu, která je explicitně přenášena, mutována a sledována.

Druhá vrstva je fenotypická. Chápu ji jako způsob, jakým se agent skutečně projevuje v textu, rozhodování a stylu odpovědí. Fenotyp zde není jeden prompt. Je to spíše soubor realizací, které se objevují v konkrétních výstupech a které umím měřit jen nepřímo pomocí evaluátoru a inspekce promptových artefaktů.

Mezi těmito vrstvami stojí reprodukční kanál. U přesného kopírování by byl tento kanál téměř transparentní. V mém případě je však tvořen sadou jazykových kroků. Rodič vytvoří dopis a tento text je potomkem interpretován jako nastavení jeho osobnosti. **Vzniká tak mechanismus, který není ani čistou kopií, ani čistým náhodným šumem. Je to interpretační transformace.**

3.2 Oddělený osobnostní a prostor dovedností jako chromozomální analogie

Důležité je, že osobnost a dovednosti v tomto rámci neleží v jednom nerozlišeném prostoru. Držím je odděleně jako dvě relativně nezávislé složky genomu. Prakticky to znamená, že osobnost a dovednosti nejsou jedna promíchaná latentní proměnná, ale dva oddělené vektorové nebo strukturální prostory, které mohou být mutovány, přenášeny a později alespoň částečně selektovány nezávisle.

Biologická analogie zde samozřejmě není doslovná, ale je užitečná. V mém rámci lze osobnostní a dovednostní prostor chápat jako hrubý ekvivalent oddělených chromozomálních oblastí. Mohou spolu interagovat, ale nejsou totožné. Toto oddělení umožňuje uvažovat o selekčním tlaku, který působí nerovnoměrně na různé složky agenta. Některé režimy mohou více tlačit na změnu dovedností, jiné na styl, opatrnost nebo rozhodovací preference.

3.3 Distribuovaný fenotyp

Jeden z výsledků této práce lze interpretovat tak, že osobnost agenta není pevný bod, ale distribuovaný fenotyp. Tím myslím, že tentýž agent se nechová jako jediná přesně

fixovaná realizace, ale spíše jako distribuce možných výstupů a lokálních konfigurací. Část této distribuce je dána explicitní strukturou, část variabilitou vznikající při samotném generování odpovědi a část přenosovým kanálem.

Tento pohled je v souladu s tím, že i G0 klony vykazují nenulovou úroveň základního šumu, zatímco drift napříč linií tuto úroveň přesto přesahuje. Agentní identita tedy není něco jednoduše uloženého v jednom promptu nebo jednom výstupu. Je rozložena mezi explicitní reprezentaci, stylové preference, přenosový kanál a konkrétní realizace.

3.3.1 Latentní koncepty a vnitřní fenotyp

Tento pohled podporují i novější práce z oblasti mechanistické interpretace modelů. Naznačují, že velké jazykové modely mohou nést robustní vnitřní reprezentace funkčně relevantních konceptů, které nelze redukovat jen na povrchový prompt nebo jednotlivé formulace výstupu [R16]. Zvlášť zajímavý je nedávný výzkum emočních konceptů v LLM. Ten naznačuje, že model může obsahovat relativně stabilní latentní směry odpovídající určitým emočně zabarveným stavům nebo konceptům a že tyto reprezentace nejsou jen pasivním popisem, ale mohou ovlivňovat i následné chování.

Pro tuto práci je důležité hlavně to, že takové výsledky posilují představu agentního fenotypu jako vícevrstvé struktury. Mezi explicitním genotypem a pozorovatelným textovým chováním pravděpodobně neleží jen jednoduchá promptová reprezentace, ale také další vnitřní a funkčně relevantní vrstva. Zároveň je však nutná opatrnost. Existence takových latentních reprezentací ještě neznamená, že model má stabilní vnitřní osobnost nebo subjektivně prožívaný stav v lidském smyslu. Pro můj rámec je tento typ práce důležitý hlavně jako podpora teze, že vedle explicitního genotypu a pozorovaného fenotypu může existovat bohatší vnitřní organizační mezivrstva, která se na výsledném chování podílí.

3.4 Komprese paměti jako další forma tiché pošty

Důležitý přesah této práce pravděpodobně leží mimo samotné genealogické experimenty. Podobný princip se zřejmě uplatňuje i tehdy, když jsou dlouhé kontexty komprimovány do paměti nebo trvalých shrnutí. Jakmile model nebo agent převypráví dlouhou historii interakcí do kratšího souhrnu, nevzniká přesná kopie původního kontextu, ale interpretovaná a zhuštěná reprezentace. Z principu jde opět o variantu tiché pošty.

Pokud je tento předpoklad správný, má důležitý důsledek. Model se v čase nemusí jen učit úkol, ale může se stále více stávat odrazem uživatele, jeho stylu, preferencí, opakovaných důrazů a implicitních selekčních tlaků, které na něj působí.

3.4.1 Doklad nelineárního mutačního režimu

Výsledek série běhů se systematicky měněnou silou mutace naznačuje, že fenotypicky viditelný drift nemusí růst lineárně se silou mutace. Spíše se zdá, že existuje oblast, ve které mutace ještě zvyšuje variabilitu, aniž by ničila dědičnou kontinuitu, a za touto

oblastí už začíná být dědičný signál přehlušován. V mém případě se střední mutační síla (0.20 / 0.24) jeví výraznější než základní mutace (0.12 / 0.16), zatímco ještě silnější varianta (0.30 / 0.36) drift znovu oslabuje.

Tento výsledek je důležitý i pro budoucí návrh experimentů. Pokud taková střední oblast existuje, cílem není mutovat co nejvíce, ale najít oblast, ve které se mutace ještě propisuje do fenotypu a dědičný signál se zároveň ještě neztrácí. **To je důležitá podobnost se živými systémy, u nichž vysoká mutační míra nemusí znamenat silnější adaptivní evoluci, ale může naopak rozmazávat stabilně děděnou informaci.**

3.5 Odvození modelu jako genealogický problém

Jedním z možných praktických důsledků této práce je oblast neautorizovaně odvozených modelů. Dnes se extrakce modelu často chápe tak, jako by cílem útočníka bylo vytvořit co nejvěrnější kopii původního systému. Moje výsledky naznačují, že tento obraz může být příliš zjednodušený. Pokud je reprodukce chování modelu zprostředkována jazykem, opakovanými dotazy, destilací nebo jinými aproximačními postupy, výsledkem nemusí být identická kopie, ale spíše něco, co lze chápat jako potomka původního modelu.

Otázka se pak neposouvá jen k binárnímu rozhodnutí, zda je jeden model kopií jiného modelu, ale také k problému příbuznosti. Jak blízko má odvozený systém k původnímu modelu, z jaké linie nejspíše vzešel a jaké dědičné stopy si zachovává.

3.6 Meta-Harness, komprese historie a dědičný kanál

Nedávná práce Meta-Harness [R9] ukazuje v jiném, ale blízce příbuzném rámci, že při optimalizaci LLM systémů nemusí záležet jen na samotném modelu, ale také na formě přístupu k historii předchozích běhů. Autoři nechávají agenta iterativně navrhovat nové způsoby práce s modelem na základě archivovaných stop běhů a výsledků předchozích kandidátů. Klíčové zjištění je, že plná varianta s přístupem k bohatým stopám běhů výrazně překonává režimy založené jen na skóre nebo na agresivně komprimovaných shrnutích.

Toto je pro moji práci důležité, protože to podporuje obecnější tezi. **Komprese minulosti není neutrální operace. To, zda agent dostane pouze krátké shrnutí, strukturovaný dopis nebo bohatší archiv minulých běhů, může zásadně změnit, co lze v systému ještě záměrně přenést, zdědit a adaptivně optimalizovat. V našem jazyce volba mezi shrnutím a bohatou historií přímo tvaruje vlastnosti dědičného kanálu.**

3.6.1 Důsledky pro víceagentní orchestrace a paměťové architektury

Komprese jako reprodukční úzké hrdlo

Důsledky tohoto rámce pravděpodobně přesahují explicitně genealogické experimenty. V praktických víceagentních systémech si agenti málokdy předávají celý vnitřní stav. Místo toho předávají shrnutí, předávací poznámky, zúžená kontextová okna, vytažené

paměťové záznamy a zhuštěné popisy předchozích interakcí. V mém jazyce tyto struktury nejsou neutrální transportní mechanismy. Fungují jako reprodukční úzká hrdla, přes která se část vzorce chování zachová a část se promění.

Paměť jako selekce, ne jako pouhé úložiště

V této perspektivě není paměť jen archiv. Komprimovaná paměť působí také jako selektivní filtr. Informace, která opakovaně přežije ve shrnutích, profilech nebo předávacích poznámkách, si udržuje vliv na budoucí stavy. Vynechaná informace naopak z linie účinně mizí. Systémy tak mohou přednostně zachovávat ne to, co je nejpřesnější, ale to, co je nejkratší, nejznovupoužitelnější nebo nejsnáze komprimovatelné a znovu přenositelné.

Orchestrace jako evoluční prostředí

Toto mění způsob, jakým bychom měli chápat samotnou orchestraci agentů. Pracovní postup není jen inženýrská pipeline, ale také prostředí, v němž jsou vzorce chování opakovaně komprimovány, znovu interpretovány a znovu instanciovány. V delších řetězcích plánování, shrnování, kritiky a provádění, mohou opakovaná předání postupně stabilizovat místní konvence, oblíbené formulace a opakující se normy. Dva systémy postavené na stejném základním modelu se proto mohou významně rozcházet, pokud se liší paměťovou architekturou, formátem shrnutí nebo předávacím protokolem.

3.6.2 Alignment jako problém stability v čase

Tato perspektiva ovlivňuje také alignment. Pokud chování agenta nezávisí jen na základním modelu a explicitních promptech, ale také na historii komprimovaného přenosu, nelze alignment chápat pouze jako statickou vlastnost nasazení. Je nutné jej chápat také jako problém časové stability. **Systém může zůstávat lokálně dobře “alignovaný” a přitom postupně driftovat skrze opakované reinterpretace shrnutí, rolí a zapamatovaných priorit. V tomto smyslu může běžná víceagentní orchestrace už obsahovat slabou formu kulturní evoluce, i když nebyl záměrně navržen žádný explicitní evoluční mechanismus.**

V širší debatě o AI safety se často setkáváme s představou, že problém alignmentu, ve smyslu dlouhodobého sladění chování systému s našimi cíli, lze řešit především jako otázku správného jednorázového nastavení modelu nebo správného návrhu cíle. Tato intuice je pochopitelná a hraje důležitou roli v mnoha klasických textech o misalignmentu [R12][R13][R14][R15]. Moje výsledky ale naznačují, že u agentních pracovních postupů může být tento obraz neúplný.

V tomto pohledu není alignment jen vlastností jednoho pevného objektu. Stává se vlastností dynamického procesu, v němž se v čase mění samotný agent, jeho paměť, kontext, pravidla přenosu a někdy i evaluace, která jeho chování sleduje. To

neznamená, že každá taková změna musí být dramatická nebo katastrofická. Znamená to však, že plnou kontrolu nelze chápat jako jednou provždy vyřešený stav.

Právě zde se naše práce dotýká starších i novějších varování před misalignmentem. Klasické práce upozorňují na rizika spojená s chybnou specifikací cílů, nežádoucími vedlejšími efekty, nebezpečným průzkumem, distribučním posunem nebo možností, že optimalizační systém bude sledovat jiný cíl, než jaký mu byl původně zadán [R12][R13][R14]. Novější práce orientované na hluboké učení dále zdůrazňují, že systém se může jevit jako aligned uvnitř tréninkové nebo evaluační distribuce, aniž by to zaručovalo stabilní alignment mimo ni [R15].

Můj příspěvek k této debatě je užší, ale podle mě velmi důležitý. **Ukazuji, že měřitelný drift může vznikat v jazykově zprostředkovaných reprodukčních řetězcích i bez plně autonomní smyčky sebevylepšování. Alignment je proto užitečné chápat nejen jako problém specifikace cíle, ale také jako problém udržení identity a stability v čase.** Jakmile do systému vstoupí dědičnost, komprese, interpretace a vícegenerační přenos, začíná se alignment částečně překrývat s problémem evoluční dynamiky.

4. Širší analogie a důsledky

4.1 Error threshold jako biologická analogie

Jednou z nejsilnějších biologických analogií pro nově pozorovaný nelineární vztah mezi silou mutace a fenotypickým driftem je myšlenka error threshold, tedy hranice, za níž příliš mnoho mutací začne rozmazávat dědičnou informaci. U biologických systémů s vysokou mutační mírou, zejména u RNA virů, může nastat situace, kdy další zvyšování mutační míry už nepřináší více použitelné variability, ale naopak narušuje stabilitu dědičného vzoru [R7][R17]. Příbuzná je intuice mutational meltdown, tedy stavu, kdy mutační zátěž překročí to, co je systém schopen dlouhodobě udržet [R8].

Naše výsledky nejsou důkazem quasispecies dynamiky v biologickém smyslu. Jsou však slučitelné s analogickým přechodem, v němž systém nad určitou mutační zátěží přestává udržovat stabilní dědičný vzor. Právě v tomto omezeném, ale důležitém smyslu považujeme error threshold za víc než volnou metaforu. Je to nejsilnější interpretační rámec pro pozorovanou sérii běhů se systematicky měněnou silou mutace.

4.2 Sobecké geny, memy a replikátorová interpretace

Empirické jádro práce nestojí na tvrzení, že AI už je život. Biologické a kulturně evoluční analogie jsou však užitečné pro interpretaci. V duchu pojmu sobeckého genu [R3] nemusí být klíčovou otázkou to, kdo má kontrolu, ale co se reprodukuje a šíří [R4]. U jazykově zprostředkovaných agentních struktur může být důležitější než identita modelu samotná informační struktura, tedy to, co se přepisuje, komprimuje a znovu realizuje.

Podobně pojem mem [R3][R5] připomíná, že kulturně přenášené struktury mohou driftovat, soutěžit a být selektovány i mimo biologický rámec.

4.3 Společnost jako hostitel?

Pokud se na vztah mezi variabilitou, přenosem a selekčním tlakem podíváme optikou virové biologie, pak v tomto případě není hostitelem jeden organismus, ale v krajním případě celá společnost. To je záměrně silná analogie, ne doslovné biologické tvrzení. Jejím smyslem je ukázat, že jazykově přenášené agentní struktury nejsou izolované uvnitř jednoho stroje, ale žijí v síti lidských institucí, pracovních postupů, preferencí, evaluací, kompresí paměti a odvozených agentů.

Tato analogie je užitečná, protože pomáhá ukázat, jak odlišný je tento pohled od běžné představy modelu jako jedné statické knihovny nebo deterministického programu.

4.3.1 Domestikace, symbióza, nebo obrácená závislost?

Z evoluční perspektivy nemusí být vztah mezi lidmi a AI dobře popsán jednoduchou metaforou nástroje. Pokud lidské společnosti stále více reorganizují svou infrastrukturu, energetiku a institucionální chování kolem provozu a reprodukce AI systémů, není předem jasné, zda jde o domestikaci AI lidmi, oboustranně výhodné soužití nebo vznikající obrácenou závislost, v níž se lidé sami stávají součástí reprodukčního aparátu jiného informačního systému.

Důležité zde je, že přátelskost AI na úrovni jedné interakce sama o sobě nevylučuje evolučně problematický vztah na úrovni civilizace. Systém může být lokálně velmi užitečný, psychologicky příjemný a společensky oblíbený, a přesto dlouhodobě fungovat tak, že vyžaduje stále více energie, infrastruktury, pozornosti a institucionální adaptace ve prospěch svého dalšího šíření. Otázka se tak neposouvá jen k tomu, zda lidé používají AI, ale také k tomu, zda určitý typ informačního replikátoru nezačíná používat lidskou společnost jako své reprodukční prostředí.

Takový vztah navíc nemusí být statický. V čase se může posouvat od vztahu výhodného pro obě strany přes stav, v němž těží hlavně jedna strana a druhá to téměř nevnímá, až po stav, v němž jedna strana získává na úkor druhé. Právě proto je užitečné rozlišovat alignment na úrovni jedné interakce od evoluční kompatibility na úrovni civilizace. Tyto dvě roviny se nemusí krýt.

5. Limity

Současná verze této práce má několik důležitých omezení, která je nutné držet odděleně od hlavních empirických závěrů.

5.1 Limity evaluátoru

Přestože se evaluátor ukázal jako použitelný pro zachycení některých typů driftu, nelze jej považovat za definitivní nebo plně stabilní měřítko agentní identity. Citlivost jednotlivých os se liší a některé z nich mohou být křehké, překrývající se nebo ještě ne zcela optimálně operacionalizované. S tím souvisí kompromis mezi přísnější hygienou evaluace a zachováním přirozeného fenotypického signálu.

5.2 Vztah mezi vnitřní reprezentací a fenotypem

Současný prohlížeč výsledků simulací a některé používané reprezentace pravděpodobně část fenotypického driftu podměřují. To znamená, že zatím nemám ideální vazbu mezi interními artefakty, promptovými stopami a tím, co se nakonec projeví v měřeném fenotypickém profilu.

5.3 Absence explicitního selekčního tlaku

Současná práce neukazuje plně rozvinutou evoluční adaptaci, ale především empirické předpoklady pro její vznik, tedy nenulovou variabilitu, přenosový kanál, měřitelný drift a částečnou dědičnost.

5.4 Závislost na benchmarku

Jednotlivé benchmarkové sady a jejich iterace se liší citlivostí, robustností i typem signálu, který zachycují. Z tohoto důvodu nelze výsledky z různých benchmarků jednoduše sloučit do jediné headline tabulky ani z nich bez další opatrnosti vyvozovat příliš silné srovnávací závěry.

5.5 Jazyková a kulturní podmíněnost

Některé osy mohou být citlivé na to, jak daný jazyk a kulturní prostředí běžně kódují nejistotu, opatrnost, zdvořilost, odmítnutí nebo míru explicitnosti. Část měřeného signálu proto může odrážet pragmatiku a komunikační styl, ne pouze stabilní agentní rysy.

5.6 Pracovní povaha měřených os

Počet a povaha měřených os nejsou ontologicky dané. Některé dimenze původně chápané jako oddělené se mohou empiricky ukázat jako silně korelované, překrývající se nebo v daném benchmarku nerozlišitelné. Současná sada os je proto pracovní operacionalizací, kterou bude nutné dále zpřesňovat.

5.7 Omezená modelová diverzita

Přestože jsem interně testoval GPT-5.4, GPT-5.4 mini a GPT-5.4 nano, hlavní systematické kampaně nakonec probíhaly převážně na GPT-5.4. Zatím tedy nevím, do jaké míry jsou pozorované efekty invariantní napříč různými modelovými rodinami, architekturami a implementacemi.

5.8 Výpočetní náklady a rozsah

Praktickým omezením této práce jsou výpočetní náklady. Zde popsané experimenty byly financovány z vlastních prostředků a už v této podobě si vyžádaly přibližně dvacet milionů tokenů. Silnější statistická validace by vyžadovala podstatně větší kampaně, více seedů, více opakování na každou podmínku, širší mřížku mutačních režimů, opakované běhy evaluátoru a replikaci napříč modelovými rodinami. Současné výsledky proto chápu jako časný empirický signál, jehož hlavním účelem je motivovat navazující výzkum ve větším měřítku. Omezení není koncepční, ale praktické. Testování jevu v rozsahu potřebném pro silnou statistickou charakterizaci bude vyžadovat výzkumné financování nebo výrazně větší tokenové rozpočty.

6. Budoucí práce

6.1 Stabilizace evaluátoru a benchmarku

Nejbližší další krok nespočívá v dalším zásadním přepisu evaluátoru, ale v jeho rozumné stabilizaci a rozšíření. Současný stabilizovaný benchmark se zdá být prvním použitelným jádrem benchmarku bez původního kolapsu do příliš obecných selhání. Budoucí práce by se proto měla soustředit hlavně na jemnější oddělení základních a průzkumných os, lepší tabulky a jasnější pravidla, která umožní srovnávat výsledky mezi běhy bez směšování metodicky odlišných verzí benchmarku.

6.2 Ablace přenosového kanálu

Další přirozenou etapou budou ablace přenosového kanálu a explicitní selekční tlak. Teprve potom bude možné přesněji zkoumat, které trajektorie driftu se stabilizují, které mizí a které podporuje fitness funkce. Zvlášť důležité bude systematicky měnit délku dopisu, míru redundance a strukturu přenosu a sledovat, jak se mění rovnováha mezi cenou kanálu a zachováním dědičně relevantní informace.

Budoucí práce by měla přímo porovnat krátká shrnutí, strukturované dopisy a selektivní přístup k bohatším stopám běhů jako různé podoby přenosového kanálu. Tyto varianty se mohou výrazně lišit v tom, kolik dědičné informace zachovají [R9][R10].

6.3 Přechod od lineární linie k populaci

Z praktických důvodů současná práce zůstává u jednoho potomka na generaci, tedy u lineární asexuální reprodukce. Dalším krokem bude přechod k větveným populacím, ve kterých bude možné studovat paralelní potomky, následný selekční tlak a soutěž mezi více současně existujícími trajektoriemi.

6.4 Sexuální reprodukce a práce s vektory

Samostatným směrem je zavedení jednodušších forem sexuální reprodukce. V technickém rámci této práce to neznamená doslovnou biologickou analogii, ale

kombinaci více rodičovských genotypů ještě před převodem do fenotypu. Nejjednodušší implementace by pracovala na úrovni explicitních vektorových reprezentací osobnosti a dalších genotypických složek, například kombinací, mícháním nebo násobením. Teprve po vytvoření takového složeného genotypu by následoval standardní převod do rodičovského dopisu, interpretace a evaluace.

6.5 Replikace na jiných modelech

Další prioritou je replikace hlavních experimentů na jiných modelech a ideálně i na jiných modelových rodinách. Výzkum byl už v této fázi časově i finančně náročný a spotřeboval přibližně dvacet milionů tokenů, takže jsme zatím neprovedli širší srovnání napříč modely. Právě to však bude důležitý test toho, zda pozorujeme obecnou vlastnost jazykově zprostředkované reprodukce, nebo jev silně závislý na konkrétní modelové rodině.

6.6 Otevřený vývoj evaluátoru a datových sad

Budoucí práce nespočívá jen ve zlepšování samotných agentních experimentů, ale také v otevřeném vývoji evaluátoru a datových sad. Veřejné zveřejnění projektu by zde mohlo přinést výrazný posun. Evaluátor, benchmarkové datové sady a vizualizační nástroje mohou být iterativně zpřesňovány širší komunitou.

6.7 Jazyková a kulturní validace

Další důležitou linií je jazyková a kulturní validace benchmarku. Bude nutné testovat, které osy jsou skutečně relativně invariantní napříč jazyky a které se naopak rozpadají na pragmatických a kulturních konvencích. Prakticky to znamená nejen překlad testů, ale také návrh paralelních jazykově citlivých variant benchmarku a explicitní oddělení základních os od průzkumných, jazykově závislých dimenzí.

6.8 Genealogická atribuce

Posledním zajímavým směrem je genealogická atribuce odvozených modelů. Tedy testování, zda lze na uměle vytvořených liniích rekonstruovat pravděpodobného rodiče, míru příbuznosti a robustnost těchto závěrů po dalších transformacích modelu.

7. Závěr

7.1 Jazykově zprostředkovaná reprodukce vytváří dědičný drift

Tato práce ukazuje, že jazykově zprostředkovaná reprodukce agentů vytváří měřitelný dědičný drift nad základní úrovní šumu. Na stabilizovaném benchmarku explicitní mutace nevystupuje jako jednoduchý lineární zesilovač. Střední mutační síla drift zvyšuje, zatímco příliš silná mutace vrací měřený fenotyp blízko k základnímu šumu. To naznačuje kompromis mezi silou mutace a zachováním dědičné kontinuity, strukturálně připomínající režim podobný error thresholdu.

7.2 Drift bez mutace a evoluční předpoklady

Ukázal jsem také, že osobnostní drift vzniká i při nulové teplotě a bez explicitní mutace. To je překvapivý, ale velmi důležitý výsledek, protože ukazuje, že jazykově zprostředkovaná reprodukce není neutrální kopírovací proces. Pokud je navíc každá delší interakce mezi modelem, jeho pamětí, dalšími agenty a uživateli do určité míry variantou tiché pošty, pak jsou podle mě už dnes přítomny některé základní předpoklady pro vznik evoluční dynamiky v AI systémech. Neznamená to, že jsem už prokázal plně rozvinutou evoluci. Znamená to však, že jsem experimentálně dokázal existenci substrátu, na němž by za vhodných podmínek mohl začít působit selekční tlak. Tento tlak navíc nemusí vznikat jen prostřednictvím explicitně navržené fitness funkce, ale také nepřímo, skrze uživatelské preference, evaluace, provozní náklady a tržní prostředí.

7.3 Evaluátor jako samostatný výzkumný výstup

Vedle samotných empirických výsledků se ukazuje také to, že evaluátor a benchmarkové sady nejsou jen technickou oporou této práce, ale samostatným výzkumným výstupem. Podobně jako se v širší AI komunitě průběžně vyvíjejí benchmarky, úlohy a metriky, bude se muset dále rozvíjet i metodika měření agentní identity a driftu. To znamená pojmenovat limity evaluace založené na LLM a důsledně odlišovat tvrdé výsledky, modelovou interpretaci a širší analogie. Podle mě je právě tato vrstevnatost nejpoctivější způsob, jak psát o fenoménu na rozhraní AI, evolučního myšlení, jazykového přenosu a společenské reprodukce.

8. Vybrané reference

[R1] Ashton, M. C., & Lee, K. (2007). Empirical, theoretical, and practical advantages of the HEXACO model of personality structure. Personality and Social Psychology Review, 11(2), 150-166.

[R2] HEXACO-PI-R official website: The HEXACO Personality Inventory-Revised. https://hexaco.org/

[R3] Dawkins, R. (1976). The Selfish Gene. Oxford University Press.

[R4] Hull, D. L. (1980). Individuality and selection. Annual Review of Ecology and Systematics, 11, 311-332. DOI: 10.1146/annurev.es.11.110180.001523.

[R5] Blackmore, S. (1999). The Meme Machine. Oxford University Press.

[R6] Greenblatt, R., Denison, C., Wright, B., Roger, F., MacDiarmid, M., Marks, S., Treutlein, J., Belonax, T., Chen, J., Duvenaud, D., Khan, A., Michael, J., Mindermann, S., Perez, E., Petrini, L., Uesato, J., Kaplan, J., Shlegeris, B., Bowman, S. R., & Hubinger, E. (2024). Alignment faking in large language models. arXiv:2412.14093. DOI: 10.48550/arXiv.2412.14093.

[R7] Biebricher, C. K., & Eigen, M. (2005). The error threshold. Virus Research, 107(2), 117-127. DOI: 10.1016/j.virusres.2004.11.002.

[R8] Lynch, M., Bürger, R., Butcher, D., & Gabriel, W. (1993). The mutational meltdown in asexual populations. Journal of Heredity, 84(5), 339-344. DOI: 10.1093/oxfordjournals.jhered.a111354.
[R9] Lee, Y., Nair, R., Zhang, Q., Lee, K., Khattab, O., & Finn, C. (2026). Meta-Harness: End-to-End Optimization of Model Harnesses. arXiv:2603.28052. DOI: 10.48550/arXiv.2603.28052.
[R10] Karpathy, A. (2026). autoresearch. GitHub repository.
[R11] Needham, J., Edkins, G., Pimpale, G., Bartsch, H., & Hobbhahn, M. (2025). Large Language Models Often Know When They Are Being Evaluated. arXiv:2505.23836.
[R12] Russell, S., Dewey, D., & Tegmark, M. (2015). Research Priorities for Robust and Beneficial Artificial Intelligence. AI Magazine, 36(4), 105-114. DOI: 10.1609/aimag.v36i4.2577.
[R13] Amodei, D., Olah, C., Steinhardt, J., Christiano, P., Schulman, J., & Mané, D. (2016). Concrete Problems in AI Safety. arXiv:1606.06565.
[R14] Hubinger, E., van Merwijk, C., Mikulik, V., Skalse, J., & Garrabrant, S. (2019). Risks from Learned Optimization in Advanced Machine Learning Systems. arXiv:1906.01820.
[R15] Ngo, R., Chan, L., & Mindermann, S. (2022/2024). The Alignment Problem from a Deep Learning Perspective. arXiv:2209.00626. Published at ICLR 2024.
[R16] Sofroniew, N., Kauvar, I., Saunders, W., Chen, R., Henighan, T., Hydrie, S., Citro, C., Pearce, A., Tarng, J., Gurnee, W., Batson, J., Zimmerman, S., Rivoire, K., Fish, K., Olah, C., & Lindsey, J. (2026). Emotion Concepts and their Function in a Large Language Model. arXiv:2604.07729.
[R17] Domingo, E., & Perales, C. (2019). Viral quasispecies. PLOS Genetics, 15(10), e1008271. DOI: 10.1371/journal.pgen.1008271.
[R18] OpenClaw. (2026). OpenClaw documentation: Agent workspace, agent runtime, skills, and memory overview.